

## 2026 《人工智能导论》大作业

任务名称： 可解释的谣言检测

完成组号： 5

小组人员： 郑诗霏、李梓涵、张梦溪

完成时间： 2026.6.20

## 1. 任务目标

本项目实现了安全对抗、数据处理、模型训练、结果预测和性能评估等功能，对输入文本自动判断其属于谣言或非谣言，并输出预测结果。

完成分类后，项目在 `val.csv` 上评估模型性能，统计准确率、精确率、召回率和 F1 值等指标，并提供可解释指标，帮助分析模型判断依据。

## 2. 具体内容

### (1) 实施方案

项目方案采用“输入规范化与防御 + TF-IDF 集成分类 + 相似样本检索 + 证据融合 + 可解释输出”，保证模型轻量可复现并提高精确度与可解释性。

#### 数据预处理：

1. 小写化处理
2. 清理隐形字符、同形字符、异常空白和重复拉长字符
3. 保留词级与字符级 `n-gram` 表达，适配短文本和社交媒体写法
4. 提取轻量 `claim` 结构特征，并检测 URL、@、#、标点、大小写等模式

#### 特征构建：

使用多种特征组合：

1. word unigram / bigram TF-IDF
2. character `n-gram` TF-IDF
3. 文本元信息与 `claim` 结构信号
4. 训练集相似样本检索得到的标签分布证据

#### 分类模型：

采用多个轻量级 TF-IDF 线性模型进行训练，最终选取 `char_only` 与 `char_word_with_meta` 两个分支进行加权集成，权重分别为 0.65 和 0.35。相关阈值、权重和检索参数通过优化获得。

#### 可解释性模块（RAG 思想）：

引入轻量级检索机制，从训练集中检索 Top-3 相似样本，统计其标签分布形成证据，并与基础模型结果融合。项目支持调用学校大语言模型生成自然语言解释证据、进行润色。

## （2）核心代码分析

项目的主要代码结构如下：

```
.
|-- train.py                # 训练与调参入口
|-- evaluate.py            # 评估入口
|-- robustness_eval.py     # 字符级合成扰动鲁棒性评估入口
|-- predict.py            # 单条文本预测入口
|-- web_app.py            # 本地 Web UI 服务
|-- web/                  # 浏览器端页面资源
|-- Makefile              # 常用命令封装
|-- README.md
|-- EXPERIENTS.md
|-- requirements.txt
|-- train.csv
|-- val.csv
|-- tests/
`-- src/
    |-- text_model.py      # 文本标准化、TF-IDF 模型、指标计算
    |-- ensemble_model.py  # TF-IDF 集成模型
    |-- defense.py         # 输入清洗与防御
    |-- retriever.py       # 相似训练样本检索
    |-- evidence.py        # 检索证据特征
    |-- claim_structure.py  # 轻量级 claim 结构特征
    |-- evidence_pipeline.py # 最终证据融合推理流水线
    |-- llm_explainer.py   # 学校 LLM 解释客户端
    `-- prediction_service.py # CLI 和 Web 共用预测服务
```

项目主要由训练、评估、预测、鲁棒性测试、证据解释和 Web 服务组成。

训练模块 `train.py` 负责数据读取、内部划分、候选模型训练、参数搜索和模型保存。程序将 `train.csv` 按 `event+label` 分层划分为 `fit/dev` 两部分，`fit` 集训练候选 TF-IDF 子模型，`dev` 集选择集成分支、集成权重、基础阈值、证据 `top-k`、证据融合权重和检索门限。最终采用 `char_only` 与 `char_word_with_meta` 两个子模型集成，权重分别为 0.65 和 0.35；完成内部选择后，再用完整 `train.csv` 重新拟合最终模型。

`evidence_pipeline.py` 是证据增强推理模块。基础模型输出谣言概率后，系统利用 TF-IDF 相似度从训练集中检索相似样本，统计检索样本标签分布，并与 `claim` 结构特征共同进行证据感知融合。最终模型将保存 `retrieval accuracy guard`：高置信非谣言样本的相似证据明显支持非谣言，或谣言样本被相似证据支持时进行适度 `rescue`，从而提高预测稳定性。

`predict.py` 提供单条文本预测功能，用户输入文本后，系统返回预测标签、最终谣言概率、置信度、基础模型概率、检索统计、`claim` 结构特征、

decision\_factors、probability\_guard 状态以及解释信息。预测结果展示基础概率和证据增强后的最终概率，便于分析检索证据对模型判断的影响。

此外，系统提供 evaluate.py 用于验证集评估，robustness\_eval.py 用于字符级扰动鲁棒性评估，web\_app.py 用于本地网页交互，并支持关键词贡献分析、相似样本展示、本地证据解释以及大语言模型辅助解释等功能，从而提高模型结果的可解释性和可复现性。

### （3）检测结果分析

本项目在 val.csv 验证集上进行评估，验证集大小为 401 条样本。最终评估结果如下：

```
Overall
accuracy: 87.28%
precision: 88.75%
recall: 81.14%
f1: 84.78%
threshold: 0.467000
confusion: TN=208 FP=18 FN=33 TP=142
```

各指标含义如下：

- 1. accuracy 为 87.28%，整体分类正确率较高
- 2. precision 为 88.75%，说明模型判为谣言的样本中，大部分确为谣言
- 3. recall 为 81.14%，模型成功识别约八成真实谣言
- 4. F1 值为 84.78%，模型在精确率和召回率之间取得较好平衡
- 5. 最终分类阈值为 0.467，即当最终谣言概率高于 0.467 时，模型输出 rumor
- 6. TN=208：非谣言，模型判断为非谣言
- 7. FP=18：非谣言，模型误判为谣言
- 8. FN=33：谣言，模型漏判为非谣言
- 9. TP=142：谣言，模型判断为谣言

结果表明模型具有较好的整体性能，误报较少，但仍存在部分谣言漏检现象。这主要与短文本信息不足、事件背景缺失、训练样本覆盖有限有关。

分事件评估显示，不同事件上的表现存在差异，说明模型对部分事件具有较强泛化能力，而对少量事件仍有提升空间。

总体来看，在轻量级模型条件下，系统取得了较好的检测效果，并兼顾了运行效率与可复现性。

#### 对抗样本与鲁棒性评估

项目利用 robustness\_eval.py 生成字符级对抗样本，包括隐形字符插入、同形字符替换、字符重复、空白扰动、大小写变化和标点扰动等方式。

评估结果显示：

- 1. Clean Accuracy: 87.28%
- 2. Attacked Accuracy: 87.07%
- 3. Accuracy Drop: 0.21%
- 4. Prediction Consistency: 99.79%

说明输入规范化策略和字符级特征能够有效抵抗常见文本扰动，模型具有较好的鲁棒性。

## （4）判断依据的分析

运行过程中，系统除了给出最终分类结果外，还会展示影响预测的重要关键词以及训练集中最相似的样本。

TF-IDF 特征权重提供了关键词，可以反映模型关注的核心内容；检索证据来自训练集中相似文本及其标签分布，可以说明当前判断是否有相似案例支持。系统还会输出 `baseline_prob_rumor` 与 `prob_rumor`，展示证据融合前后的概率变化。

此外，系统会返回若干相似训练样本及其标签信息，帮助用户理解模型为何做出当前判断。当模型出现误判时，也可以通过查看相似样本分布分析原因。

为了提高结果可读性，项目支持大语言模型解释模块。该模块仅根据本地模型已经生成的标签、概率、关键词和 RAG 式相似样本证据生成自然语言说明，不参与训练、阈值选择和最终分类决策；如果未配置 API key，系统仍可正常完成本地预测，只是 `llm_evidence` 显示为不可用。

## 3. 工作总结

### （1）组内分工

#### 郑诗霏：模型基础、训练流程与鲁棒性

主要负责项目基础框架搭建、数据读取与预处理、文本规范化、TF-IDF 基线模型设计、TF-IDF 双模型集成方案、`train.py` 训练脚本以及 `robustness` 实现。该部分完成了模型从数据输入、对抗攻击、特征提取、候选模型训练、模型组合选择到最终模型保存的完整训练流程。

#### 李梓涵：证据增强与可解释性模块

主要负责相似样本检索器、检索证据特征、声明结构特征、证据感知融合机制、`RumorDetectionPipeline` 推理流程、基于证据的解释生成，以及学校大语言模型解释提示词约束设计。该部分使系统不仅能够输出分类结果，还能够给出关键词、相似样本和判断依据，提高了模型的可解释性。

#### 张梦溪：评估、预测与应用展示

主要负责 `evaluate.py` 评估脚本、`predict.py` 单条预测脚本、`web_app.py` 本地网页服务、Web UI 页面、共享预测服务 `RumorPredictionService`、异常输入检测、测试用例、`Makefile`。该部分保证了模型可以被完整评估、命令行调用和网页展示，并提升了项目的可复现性与易用性。

### （2）收获、心得

我们系统学习了一个简易模型搭建的完整流程，包括数据预处理、特征工程、模型训练、结果评估和系统部署。实践表明，TF-IDF 等传统方法在中小规模文本分类任务中仍具有较好的效果。同时，我们认识到模型可解释性的重要性，仅给出预测结果不具备可解释性，有必要提供关键词、相似样本等证据支持。

### （3）遇到问题及解决思路

项目实施过程中主要遇到四类问题：短文本信息量不足、高频关键词造成误判、不同事件间的数据分布差异，以及社交媒体文本容易受到字符问题变化的干扰。针对这些问题，我们引入相似样本检索、证据感知概率融合、`retrieval accuracy`

guard 和字符级输入规范化策略，提高了模型的稳定性和解释能力。对于可解释性需求，则采用“本地证据生成 + LLM 语言润色”的方案，在保证分类决策可复现的同时提升了说明文字的可读性。

#### **4. 课程建议**

本次实验训练数据较少，训练出的模型精度有限，或许可以提供更多真实场景数据，乃至对抗样本数据，对于安全性方面可开发更多。另外或许可以由英文样本推广至中文样本，加强模型泛化性。